

OpenGEN-1: 从第一性原理重构 GEN-1

这是一篇从第一性原理出发对 GEN-1 模型的重构，依据来自 Generalist AI 发布的证据、演示、博客，以及 Pete / Andy 的博客和访谈。

核心判断是：

GEN-1 是一个主要基于物理交互流训练出来的物理基础模型，而不是一个从 **VLM** 改造而来的 **VLA**。

Pete Florence 和 Generalist 团队明确强调了区别：GEN-1 “不是一个把机器人动作硬接到上面的微调版视觉语言模型”，也“不只是一个世界模型” [1]。他们把它称为一个面向物理交互的原生基础模型 [1]。

这个说法很重要。它意味着模型主要学习的不是语言、物体语义，或被动的视频预测。它学习的是物理交互的结构：感知、动作、接触、失败、恢复、速度和后果。

从语义常识到物理常识

在互联网规模数据上训练的 LLM 和 VLM 可以吸收大量语义知识。它们知道苹果是什么，通常是什么颜色，通常在哪里出现，人们通常会对它做什么。

但它们缺少更深层的东西：物理常识 [2]。

如果我把一个苹果向左推，它可能会向左滚。如果前面有一个盒子，它会被挡住。如果我拿着它而它开始滑落，我会收紧手指。这些并不只是视觉事实。它们来自动作及其后果。

Andy Zeng 的文章直接指出了这一点：如果大规模文本带来的是语义常识，那么大规模物理交互也许能够带来物理常识——但前提是数据保留了这个闭环 [2]。

这里有两个层次：

前向物理常识：如果我采取这个动作，接下来会发生什么？

逆向 / 反射式物理常识：基于当前正在发生的事情，我应该怎么做？

前者接近动力学模型或世界模型。后者更接近策略、逆动力学模型或反射。人类会连续地同时做这两件事。我们并不是先构建一个完美的世界模型，再规划，然后行动。我们是在同一个闭环中感知和行动。


一种流式物理 token 架构

当机器人与物理世界交互时，它接收一连串感知输入，并输出一连串动作。因此，自然的架构不是一个静态的 image-to-action 网络，而是一个流式序列模型。

一种合理的架构是基于物理 token 的 block-causal transformer，其中每个 token 可以是：

- context / task token;
- image token;
- proprioception token;
- force / tactile token;
- action-condition token;
- state-query 或 action-query token。

在推理过程中，模型持续追加 observation chunk，并周期性地解码 action chunk。



这与 Generalist 自己关于 GEN-0 的描述高度一致。他们把 Harmonic Reasoning 描述为训练模型通过 sensing token 和 acting token 的异步流之间的相互作用来“同时思考和行动” [3]。

过去已处理流的 KV cache 充当短期记忆。更长程的记忆也可能由 harness 管理的 keyframe 或压缩状态摘要提供。Generalist 明确表示，GEN-1 为了实时推理需要“新的 paged attention 形式” [5]。在 transformer serving 中，PagedAttention 本质上就是一种 KV-cache 内存管理方法 [6]。

这也符合 shell-game 演示。该任务需要视觉记忆：在只有腕部摄像头的情况下，物体可能离开视野、被遮挡，或者移动到夹爪后方。只看当前帧的 policy 不够。模型需要基于最近 observation 和 state 的短期工作记忆 [4]。

动作解码可以通过几种方式实现。最简单的是类似 StarVLA-alpha 的直接 action-chunk head [17]。更强的一种选择是 OpenPI 风格的 flow action expert，其中未来动作被表示为连续的 noisy action token，模型从噪声到 clean action 预测一个 vector field [7]。另一种合理选择是类似 GR00T 的 diffusion transformer action module，其中一个快速动作模型基于视觉-语言-本体感知上下文生成流畅的电机动作 [8]。

训练目标: 动作预测 + 潜在动力学

标准 VLA 目标是动作预测损失, 也就是预测动作和 ground-truth 动作之间的损失, 或者在 flow matching 中预测 velocity。

这教会模型逆问题:


给定当前历史, 我接下来应该做什么?

但如果要学习物理常识, 仅靠动作预测可能不够。模型还应该学习前向问题:

给定当前历史和一个动作, 接下来会出现什么物理状态?

这就是世界模型思想有用的地方。但完整 RGB 重建可能太昂贵, 而且容易被无关像素细节干扰。模型不需要重建每一个背景纹理。它需要预测与动作相关的物理状态。

更好的目标是 latent future prediction, 也就是让预测的未来 latent state 与编码出来的未来 state 对齐。



这就是“VLA + world model + beyond”的技术含义。Pete 说 Generalist 花了一年多时间结合“VLAs、world models 以及更多东西”的思想, 因为一个模型结合的能力越多, 就越难被分类 [1]。

对于 policy inference 来说, 如果模型有丰富的 image / proprio history, 过去预测过的动作并不是严格必要的。state trajectory 已经包含了它们的大部分效果。但对于 world-model training 来说, 干净的 action-condition token 很有用, 因为它们可以教会模型因果动力学。

不过, 如果 encoder 和 predictor 都可以自由训练, latent reconstruction 可能会 collapse。target latent 应该被锚定:

$z_target = \text{stopgrad}(E_EMA \text{ or } \text{frozen}(o_future))$

V-JEPA 风格的方法使用 latent-space prediction、stop-gradient target encoder、masking 和 predictor asymmetry 来避免 collapse [9]。对于物理基础模型来说, action loss 本身也是一个 anti-collapse anchor, 因此公式可以更简单。

一个简洁的目标可以写成:

$L = L_action + \lambda_1 L_future-latent + \lambda_2 L_proprio + \lambda_3 L_contact/force$

这个目标结合了逆动力学、latent 前向动力学、本体感知预测, 以及接触 / 力预测。

物理交互数据

互联网文本和视频可以提供语义先验, 但它们不包含完整的物理闭环。大多数互联网视频缺少准确的动作、本体感知、力、抓握、触觉反馈和恢复轨迹。

Generalist 的主张是, 可以通过大规模收集物理交互来打破数据瓶颈。GEN-1 使用超过 50 万小时的高保真物理交互数据训练 [5]。更重要的是, 它的基础模型不使用机器人数据训练; 相反, 它使用低成本可穿戴设备采集的人类完成数百万种活动的的数据 [5]。

这与 Andy 的数据论点一致。遥操作往往会因为延迟、有限的触觉反馈和不自然的接口而破坏 sensorimotor loop; Generalist 则构建了手持式人体工学设备, 让力反馈存在, 并让操作者开始“反应”, 而不是“思考” [2]。

数据多样性不应该只是语义多样性, 也就是不同物体、场景和任务。它还应该包括交互多样性:

- 用力过大 → 物体变形或撞击;
- 用力过小 → 物体滑落;
- 抓取不好 → 重新抓取;

这就是触觉和力数据变得关键的地方。视觉告诉机器人物体在哪里。本体感知告诉它机器人在哪里。触觉和力告诉它实际发生了什么物理交互。

Generalist 的博客称 GEN-1 使用超过 500,000 小时的交互数据训练 [5]。假设数据以 10 Hz 记录:

$500,000 \times 3600 \times 10 = 18B$

所以, 如果每个 timestep 被压缩成大约 64–256 个 visual token, 那么总 token 数大约是 1.15T–4.61T。这里还没有加入 proprioception、action、tactile、force 和 task token。因此, 这个数据集已经处于 trillion-token 量级。

与常见 LLM / VLM 对比：

Model family	Model size	Pretraining tokens	Notes
Llama 2	7B / 13B / 70B	2.0T text tokens	Llama 2 三个尺寸报告的 token 数相同 [10]。
Llama 3	8B / 70B	15T+ text tokens	Meta 报告两个 Llama 3 尺寸都使用 15T+ 预训练 token [11]。
Qwen2-VL	2B / 8B / 72B	~1.4T multimodal tokens	Open-Qwen2VL 报告 Qwen2-VL 使用约 1.4T multimodal pretraining tokens [12, 13]。

这个数据规模已经足够训练一个 10B 级别的物理基础模型，尤其是因为这些 token 在因果物理信息上非常密集。

这也与 GEN-0 的 scaling observation 一致：Generalist 报告说在约 7B 参数附近出现 phase transition，称 7B+ 模型能更好地内化大规模机器人预训练数据，并指出 GEN-0 已经扩展到 10B+ 的模型规模 [3]。

关键不只是 token 数。1T web token 和 1T physical-interaction token 并不等价。Web token 在语义信息上很密集。Physical-interaction token 在接触、动作、失败、修正、记忆和后果上很密集。

100 Hz 推理需要一个系统

Generalist 早期的 research preview 表示，机器人会把像素和其他传感器数据映射成 100 Hz 动作，并且完整的软硬件栈能够实现反应式、流畅、精确的控制 [16]。

对于一个 10B 模型，使用 fp16 / bf16 时，仅权重就大约是 20GB。在 batch size 为 1 时，next-token 或 action-query decoding 通常受限于 memory bandwidth。先忽略其他开销。

近似的带宽下界估计：

GPU	Memory bandwidth	fp16 10B weight-read lower bound	More realistic optimized range
RTX 5090	~1.79 TB/s	~11 ms	~11–25 ms
RTX PRO 6000 Blackwell	~1.79 TB/s	~11 ms	~11–25 ms
L40S	864 GB/s	~23 ms	~25–60 ms

这些只是 weight-read lower bound。真实推理还要支付 KV-cache 读取、vision encoding、action expert steps、kernel overhead、scheduling、robot I/O, 以及 safety / control logic 的开销。

因此, 可能的设计是:

大模型:

- 以较低 policy frequency 运行;
- 通过 KV cache / paged attention 维护记忆;
- 解码 action chunk;
- 预测或跟踪 latent physical state。

低层 harness:

- 以 100 Hz 执行;
- 混合 action chunk;
- 执行 safety 约束;
- 处理 impedance / force / gripper control;
- 对 tactile 和 proprioceptive events 做出反应;
- 在两次模型调用之间平滑和稳定行为。

这解释了为什么 Generalist 说 GEN-1 更准确地说是一个系统, 而不仅仅是一个模型 [5]。

结论

最关键的隐藏洞见是:

GEN-1 不只是一个更好的机器人策略。它是在尝试构建一个面向物理交互的预训练基底。

这与其他 VLA 形成对比。其他 VLA 通常从预训练 VLM 初始化, 并使用大量 web data 共同训练模型, 从而学习语义常识。而 GEN-1 似乎瞄准的是缺失的那一层: 从真实交互的密集流中学习到的物理常识。

Generalist 的演示大多聚焦于展示物理常识上的泛化: 接触丰富的操作、遮挡、恢复、流畅性。相比之下, 很多 π 系列 / VLM-based robot models 更强调语义或任务层面的泛化: 遵循指令、处理未见过的物体, 以及跨高层任务描述迁移。

References

[1] Pete Florence and Generalist AI Team, “Going Beyond World Models & VLAs,” Generalist AI Blog, Apr. 7, 2026.

[2] Andy Zeng, “The Dark Matter of Robotics: Physical Commonsense,” Generalist AI Blog, Jan. 29, 2026.

- [3] Generalist AI Team, “GEN-0 / Embodied Foundation Models That Scale with Physical Interaction,” Generalist AI Blog, Nov. 4, 2025.
- [4] Generalist AI, “GEN-1 Plays the Shell Game,” LinkedIn post, Apr. 2026.
- [5] Generalist AI Team, “GEN-1: Scaling Embodied Foundation Models to Mastery,” Generalist AI Blog, Apr. 2, 2026.
- [6] Woosuk Kwon et al., “Efficient Memory Management for Large Language Model Serving with PagedAttention,” arXiv, 2023.
- [7] Physical Intelligence / Black et al., “ π_0 : A Vision-Language-Action Flow Model for General Robot Control,” arXiv, 2024.
- [8] NVIDIA et al., “GR00T N1: An Open Foundation Model for Generalist Humanoid Robots,” arXiv, 2025.
- [9] Meta AI, “V-JEPA: Revisiting Feature Prediction for Learning Visual Representations from Video,” ICLR / OpenReview, 2024.
- [10] Meta, “Llama 2 Model Card,” Hugging Face, 2023.
- [11] Meta, “Meta Llama 3 8B Model Card,” Hugging Face, 2024.
- [12] Wang et al., “Open-Qwen2VL: Compute-Efficient Pre-Training of Fully-Open Multimodal LLMs on Academic Resources,” arXiv, 2025.
- [13] Peng Wang et al., “Qwen2-VL: Enhancing Vision-Language Model’s Perception of the World at Any Resolution,” arXiv, 2024.
- [14] Shuai Bai et al., “Qwen2.5-VL Technical Report,” arXiv, 2025.
- [15] Qwen Team, “Qwen2.5 Technical Report,” arXiv, 2024.
- [16] Generalist AI Team, “Research Preview,” Generalist AI Blog, Jun. 17, 2025.
- [17] Ye et al., “StarVLA- α : Reducing Complexity in Vision-Language-Action Systems,” arXiv, 2026.